



Министерство науки и высшего образования Российской Федерации  
Федеральное государственное бюджетное образовательное учреждение  
высшего образования  
«Московский государственный технический университет  
имени Н.Э. Баумана  
(национальный исследовательский университет)»  
(МГТУ им. Н.Э. Баумана)

---

ФАКУЛЬТЕТ \_\_\_\_\_ Информатика и системы управления

КАФЕДРА \_\_\_\_\_ Системы обработки информации и управления

## Отчёт по рубежному контролю №2

По дисциплине:  
«Технологии машинного обучения»

Выполнил:

Студент группы ИУ5-63Б

(Подпись, дата)

**Ваксина И.Р.**

(Фамилия И.О.)

Проверил:

(Подпись, дата)

**Гапанюк Ю.Е.**

(Фамилия И.О.)

Москва, 2021

Задание.

Для заданного набора данных (по Вашему варианту) постройте модели классификации или регрессии (в зависимости от конкретной задачи, рассматриваемой в наборе данных). Для построения моделей используйте методы 1 и 2 (по варианту для Вашей группы). Оцените качество моделей на основе подходящих метрик качества (не менее двух метрик). Какие метрики качества Вы использовали и почему? Какие выводы Вы можете сделать о качестве построенных моделей? Для построения моделей необходимо выполнить требуемую предобработку данных: заполнение пропусков, кодирование категориальных признаков, и т.д.

Набор данных:

1. <https://www.kaggle.com/brsdincer/star-type-classification>

## Импорт библиотек

```
In [1]: import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from pandas.plotting import scatter_matrix
from sklearn.model_selection import train_test_split
import warnings
warnings.filterwarnings('ignore')
sns.set(style="ticks")
%matplotlib inline
```

```
In [2]: data = pd.read_csv('Stars.csv')
```

```
In [3]: data.head()
```

```
Out[3]:
```

	Temperature	L	R	A_M	Color	Spectral_Class	Type
0	3068	0.002400	0.1700	16.12	Red	M	0
1	3042	0.000500	0.1542	16.60	Red	M	0
2	2600	0.000300	0.1020	18.70	Red	M	0
3	2800	0.000200	0.1600	16.65	Red	M	0
4	1939	0.000138	0.1030	20.06	Red	M	0

```
In [4]: data.dtypes
```

```
Out[4]: Temperature      int64
L                        float64
R                        float64
A_M                     float64
Color                   object
Spectral_Class          object
Type                   int64
dtype: object
```

```
In [5]: data.drop(['Color', 'Spectral_Class', 'Color'], axis = 1, inplace = True)
```

```
In [6]: data.isnull().sum()
# проверим есть ли пропущенные значения
```

```
Out[6]: Temperature      0
L                        0
R                        0
A_M                     0
Type                   0
dtype: int64
```

```
In [7]: data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 240 entries, 0 to 239
Data columns (total 5 columns):
#   Column      Non-Null Count  Dtype
---  ---
0   Temperature  240 non-null    int64
1   L            240 non-null    float64
2   R            240 non-null    float64
3   A_M          240 non-null    float64
4   Type         240 non-null    int64
dtypes: float64(3), int64(2)
memory usage: 9.5 KB
```


In [8]: `data.head()`

```
Out[8]:
```

	Temperature	L	R	A_M	Type
0	3068	0.002400	0.1700	16.12	0
1	3042	0.000500	0.1542	16.60	0
2	2600	0.000300	0.1020	18.70	0
3	2800	0.000200	0.1600	16.65	0
4	1939	0.000138	0.1030	20.06	0

```
In [9]: #Построим корреляционную матрицу
fig, ax = plt.subplots(figsize=(15,7))
sns.heatmap(data.corr(method='pearson'), ax=ax, annot=True, fmt='.2f')
```

Out[9]: <AxesSubplot:>



```
In [10]: data['L'] = data['L'].astype(int)
X = data.drop(['L'], axis = 1)
Y = data.L
print('Входные данные:\n\n', X.head(), '\n\nВыходные данные:\n\n', Y.head())
```

Входные данные:

	Temperature	R	A_M	Type
0	3068	0.1700	16.12	0
1	3042	0.1542	16.60	0
2	2600	0.1020	18.70	0
3	2800	0.1600	16.65	0
4	1939	0.1030	20.06	0

Выходные данные:

```
0    0
1    0
2    0
3    0
4    0
Name: L, dtype: int64
```

```
In [11]: X_train, X_test, Y_train, Y_test = train_test_split(X, Y, random_state=0)
print('Входные параметры обучающей выборки:\n\n', X_train.head(), \
      '\n\nВходные параметры тестовой выборки:\n\n', X_test.head(), \
      '\n\nВыходные параметры обучающей выборки:\n\n', Y_train.head(), \
      '\n\nВыходные параметры тестовой выборки:\n\n', Y_test.head())
```

Входные параметры обучающей выборки:

	Temperature	R	A_M	Type
5	2840	0.110	16.980	0
22	7220	0.011	14.230	2
199	3463	0.675	14.776	1
97	7720	1.340	2.440	3
12	3134	0.196	13.210	1

Входные параметры тестовой выборки:

	Temperature	R	A_M	Type
109	33421	67.000	-5.79	4
71	3607	0.380	10.12	1
37	6380	0.980	2.93	3
74	3550	0.291	10.89	1
108	24345	57.000	-6.24	4

Выходные параметры обучающей выборки:

```
5    0
22   0
199  0
97   7
12   0
Name: L, dtype: int64
```

Выходные параметры тестовой выборки:

```
109   352000
71     0
37     1
74     0
108   142000
Name: L, dtype: int64
```

```
In [12]: from sklearn.tree import DecisionTreeClassifier, DecisionTreeRegressor, export_graphviz
from sklearn.tree import export_graphviz
from sklearn import tree
import re
```



```
| | | | | | | | | | | | |--- class: 132000  
| | | | | | | | | | | | |--- A_M > -9.28  
| | | | | | | | | | | | |--- class: 145000  
| | | | | | | | | | | | |--- R > 1594.00  
| | | | | | | | | | | | |--- class: 200000  
| | | | | | | | | | | | |--- A_M > -7.64  
| | | | | | | | | | | | |--- A_M <= -5.92  
| | | | | | | | | | | | |--- Type <= 4.50  
| | | | | | | | | | | | |--- Temperature <= 3587.50  
| | | | | | | | | | | | |--- class: 123000  
| | | | | | | | | | | | |--- Temperature > 3587.50  
| | | | | | | | | | | | |--- class: 320000  
| | | | | | | | | | | | |--- Type > 4.50  
| | | | | | | | | | | | |--- class: 320000  
| | | | | | | | | | | | |--- A_M > -5.92  
| | | | | | | | | | | | |--- class: 200000  
| | | | | | | | | | | | |--- Temperature > 3620.00  
| | | | | | | | | | | | |--- R <= 480.00  
| | | | | | | | | | | | |--- class: 184000  
| | | | | | | | | | | | |--- R > 480.00  
| | | | | | | | | | | | |--- A_M <= -11.58  
| | | | | | | | | | | | |--- class: 363000  
| | | | | | | | | | | | |--- A_M > -11.58  
| | | | | | | | | | | | |--- A_M <= -10.74  
| | | | | | | | | | | | |--- class: 209000  
| | | | | | | | | | | | |--- A_M > -10.74  
| | | | | | | | | | | | |--- R <= 1068.00  
| | | | | | | | | | | | |--- class: 74000  
| | | | | | | | | | | | |--- R > 1068.00  
| | | | | | | | | | | | |--- Temperature <= 3699.50  
| | | | | | | | | | | | |--- class: 310000  
| | | | | | | | | | | | |--- Temperature > 3699.50  
f depth 2 | | | | | | | | | | | | |--- truncated branch o  
| | | | | | | | | | | | |--- Temperature > 3766.00  
| | | | | | | | | | | | |--- class: 200000  
| | | | | | | | | | | | |--- Temperature > 3830.00  
| | | | | | | | | | | | |--- Temperature <= 26256.50  
| | | | | | | | | | | | |--- Type <= 3.50  
| | | | | | | | | | | | |--- A_M <= -3.89  
| | | | | | | | | | | | |--- class: 14500  
| | | | | | | | | | | | |--- A_M > -3.89  
| | | | | | | | | | | | |--- A_M <= -3.74  
| | | | | | | | | | | | |--- class: 14520  
| | | | | | | | | | | | |--- A_M > -3.74  
| | | | | | | | | | | | |--- A_M <= -3.54  
| | | | | | | | | | | | |--- class: 12450  
| | | | | | | | | | | | |--- A_M > -3.54  
| | | | | | | | | | | | |--- Temperature <= 7886.00  
| | | | | | | | | | | | |--- class: 7  
| | | | | | | | | | | | |--- Temperature > 7886.00  
| | | | | | | | | | | | |--- A_M <= -3.36  
| | | | | | | | | | | | |--- class: 4720  
| | | | | | | | | | | | |--- A M > -3.36
```

[illegible]



```

|--- R <= 1569.50
|   |--- A_M <= -9.61
|   |   |--- class: 374830
|   |   |--- A_M > -9.61
|   |   |   |--- class: 272830
|   |--- R > 1569.50
|   |   |--- class: 294903
|--- A_M > -5.96
|   |--- R <= 8.53
|   |   |--- R <= 6.13
|   |   |   |--- class: 188000
|   |   |--- R > 6.13
|   |   |   |--- R <= 6.27
|   |   |   |   |--- class: 173800
|   |   |   |--- R > 6.27
|   |   |   |   |--- R <= 6.35
|   |   |   |   |   |--- class: 28840
|   |   |   |   |--- R > 6.35
|   |   |   |   |   |--- A_M <= -4.57
|   |   |   |   |   |   |--- class: 198200
|   |   |   |   |   |--- A_M > -4.57
|   |   |   |   |   |   |--- R <= 6.63
|   |   |   |   |   |   |   |--- class: 16790
|   |   |   |   |   |   |--- R > 6.63
|   |   |   |   |   |   |   |--- class: 202900
|   |--- R > 8.53
|   |   |--- Temperature <= 37554.00
|   |   |   |--- R <= 53.00
|   |   |   |   |--- class: 198000
|   |   |   |--- R > 53.00
|   |   |   |   |--- class: 352000
|   |--- Temperature > 37554.00
|   |   |--- class: 204000
|--- A_M > 4.57
|   |--- class: 0

```

```
In [14]: from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_absolute_error, mean_squared_error, median_absolute_error
```

```
In [15]: forest_1 = RandomForestRegressor(n_estimators=5, oob_score=True, random_state=10)
forest_1.fit(X, Y)
```

```
Out[15]: RandomForestRegressor(n_estimators=5, oob_score=True, random_state=10)
```

```
In [16]: Y_predict = forest_1.predict(X_test)
print('Средняя абсолютная ошибка:', mean_absolute_error(Y_test, Y_predict))
print('Средняя квадратичная ошибка:', mean_squared_error(Y_test, Y_predict))
print('Median absolute error:', median_absolute_error(Y_test, Y_predict))
print('Коэффициент детерминации:', r2_score(Y_test, Y_predict))
```

```

Средняя абсолютная ошибка: 29120.574999999997
Средняя квадратичная ошибка: 5203187720.595
Median absolute error: 0.0
Коэффициент детерминации: 0.9230465292619281

```

```
In [17]: plt.scatter(X_test.R, Y_test, marker = 'o', label = 'Тестовая выборка')
plt.scatter(X_test.R, Y_predict, marker = '.', label = 'Предсказанные данные')
plt.legend(loc = 'lower right')
plt.xlabel('R')
plt.ylabel('L')
plt.show()
```

